

Rapport de TP : Opérations de Base en Text Mining

(Fouille de Textes avec NLTK)

Mekyassi Malak - IAGI 2

24 février 2026

1 Introduction

Ce rapport présente les résultats et les interprétations d'une série d'opérations de fouille de textes réalisées à l'aide de la bibliothèque Python **NLTK** (Natural Language Toolkit). L'objectif est d'explorer les techniques de prétraitement, d'analyse globale, de redescription sémantique et d'extraction d'informations pertinentes sur divers corpus textuels.

2 Analyse Lexicale et Statistiques de Base

2.1 Comptages et Diversité Lexicale

Une première analyse a été menée sur l'œuvre *Sense and Sensibility* de Jane Austen (1811) ainsi que sur d'autres corpus tels que *Moby Dick*.

- **Résultats bruts** : Le roman contient 141 576 mots pour un vocabulaire unique de 6 833 mots.
- **Diversité lexicale** :
 - *Sense and Sensibility* : $\sim 4.8\%$
 - *Moby Dick* : $\sim 7.4\%$
 - *Monty Python* : $\sim 12.7\%$

Interprétation : La diversité lexicale (rapport entre le vocabulaire et la longueur totale) mesure la richesse sémantique. Bien que le roman d'Austen soit littéraire, sa longueur dilue la diversité globale comparativement au script des *Monty Python*, plus court et dense en vocabulaire varié.

2.2 Analyse Comparative des Verbes Modaux

L'utilisation des modaux (*can*, *could*, *may*, *might*, *must*, *will*) a été comparée sur le corpus **Brown** selon les genres.

Interprétation : La distribution des mots reflète les tendances stylistiques. Le modal *will* domine la presse (news), marquant la projection vers l'avenir, tandis que *could* est prédominant dans la romance, traduisant l'expression du possible et du sentiment.

2.3 Filtrage des Mots Vides (Stopwords)

Le notebook illustre l'extraction des "mots inhabituels" en filtrant le vocabulaire anglais standard.

Interprétation : Dans le corpus Reuters, la fraction de mots porteurs de sens (hors *stopwords*) s'élève à $\sim 73.5\%$. Le retrait de ces mots "outils" est crucial : il permet de faire émerger la sémantique réelle. Sur le corpus "Chat", cela révèle un lexique spécifique (argot, onomatopées) invisible lors d'une lecture globale.

3 Réseaux Sémantique avec WordNet

3.1 Relations Hiérarchiques

L'utilisation de WordNet permet d'identifier les **hyponymes** (sous-classes) et les **hyponymes** (classes supérieures). Par exemple, pour le terme *motorcar*, on identifie ses classes parentes comme *motor vehicle*.

3.2 Similarité Sémantique

La distance sémantique a été calculée entre plusieurs entités :

- *Right Whale* vs *Minke Whale* : 0.25
- *Right Whale* vs *Tortoise* : ~ 0.07
- *Right Whale* vs *Novel* : ~ 0.04

Interprétation : L'algorithme basé sur l'arbre taxinomique de WordNet reflète la réalité biologique. Deux espèces de baleines partagent un ancêtre commun proche, tandis qu'un animal et un livre n'ont en commun que la racine abstraite *Entity*.

4 Normalisation et Étiquetage

4.1 Stemming vs Lemmatisation

Trois méthodes ont été comparées : *Porter*, *Lancaster* et *WordNet Lemmatizer*.

Interprétation : La **lemmatisation** est plus précise car elle respecte la morphologie linguistique (ex : *women* $\rightarrow$ *woman*). Le **stemming** (racinisation) est plus rapide mais souvent trop agressif, tronquant les mots de manière arbitraire (ex : *power* $\rightarrow$ *pow*).

4.2 Étiquetage Morphosyntaxique (POS Tagging)

L'algorithme a été testé sur des homonymes : "*They refuse to permit us to obtain the refuse permit*".

Interprétation : Le POS Tagging analyse le contexte pour distinguer le verbe du nom. C'est une étape fondamentale pour lever l'ambiguïté avant toute analyse sémantique avancée.

5 Extraction de Descripteurs (TF-IDF)

Le calcul du **TF-IDF** (*Term Frequency - Inverse Document Frequency*) a permis d'extraire les mots-clés les plus discriminants pour *Sense and Sensibility*.

Terme	Score TF-IDF
behaviour	0.00039
engagement	0.00038
sisters	0.00037
attachment	0.00026

TABLE 1 – Principaux descripteurs extraits par TF-IDF

Interprétation : Contrairement au simple comptage, le TF-IDF pénalise les mots communs à tous les livres. Les termes extraits résument parfaitement l'œuvre de Jane Austen : les relations familiales, les engagements sociaux et les conventions de comportement.

6 Conclusion

Les outils fournis par NLTK permettent de transformer un texte brut en données structurées. Du prétraitement (nettoyage, normalisation) à l'analyse sémantique (WordNet, TF-IDF), ces étapes sont essentielles pour toute application moderne de traitement automatique du langage naturel (TALN).