

Rapport de TP : Clustering de Textes via K-means

Malak Mekyassi
2ème Année IAGI

Mars 2026

1 Objectif

L'objectif est de catégoriser un corpus de documents textuels de manière non supervisée en utilisant l'algorithme **K-means**. Le défi principal consiste à identifier les thématiques dominantes et à optimiser le nombre de clusters k .

2 Méthodologie

- **Corpus** : Un jeu de données de 11 documents axé sur deux thématiques (les félins et les technologies Google).
- **Vectorisation** : Utilisation de la matrice **TF-IDF** (*Term Frequency-Inverse Document Frequency*) pour transformer les chaînes de caractères en vecteurs numériques exploitables.
- **Paramétrage** : Algorithme K-means avec initialisation **k-means++** et un maximum de 100 itérations.

3 Analyse des Résultats

Les itérations allant de $k = 2$ à $k = 10$ (stockées dans `output.txt`) révèlent les points suivants :

- **Pertinence sémantique** : Pour $k = 2$, les clusters séparent parfaitement les documents traitant de "Chats" de ceux traitant de "Google/Chrome".
- **Sur-segmentation** : À partir de $k = 4$, l'algorithme commence à isoler des documents individuels (ex : un cluster spécifique pour l'extension Chrome), ce qui nuit à la généralisation.

4 Optimisation de la valeur de k

Pour répondre à la question de l'optimisation, deux méthodes ont été appliquées :

4.1 Méthode du Coude (Elbow Method)

En observant la courbe de l'**Inertie**, une cassure nette est visible à $k = 2$. Cela indique que l'ajout de clusters supplémentaires n'apporte plus de gain significatif en termes de compacité des groupes par rapport à la complexité du modèle.

4.2 Coefficient de Silhouette

Le score de silhouette moyen a été calculé pour chaque k . Sur ce corpus de 11 documents, le pic de silhouette est atteint pour $k = 5$. C'est la configuration où la séparation entre les groupes est la plus robuste.

5 Conclusion

L'implémentation démontre que pour un petit corpus de 11 documents, l'algorithme K-means est très sensible au nombre de clusters. L'analyse croisée des méthodes de validation confirme qu'un partitionnement en **5 classes** est l'organisation la plus fidèle à la structure sémantique des données fournies.