

Compte Rendu de TP : Clustering de Corpus par K-means

Malak Mekyassi
2ème Année IAGI

Mars 2026

1 Objectif

L'objectif de ce TP est de catégoriser un corpus textuel de manière non supervisée en utilisant l'algorithme **K-means** et la vectorisation **TF-IDF**.

2 Méthodologie

- **Corpus** : 50 documents traitant de thématiques variées (Chats, Google/Tech, Cuisine).
- **Prétraitement** : Utilisation de `TfidfVectorizer` (Scikit-Learn) pour transformer le texte en vecteurs numériques en ignorant les mots vides (*stop words*).
- **Algorithme** : K-means avec initialisation `k-means++` pour une convergence optimale.

3 Analyse des Résultats

Les tests ont été effectués pour k allant de 2 à 10. Les résultats détaillés dans `output.txt` montrent :

- **À $k = 2$** : Séparation nette entre le pôle "Animaux" et le pôle "Technologie".
- **À $k = 10$** : Fragmentation excessive des thématiques (sur-segmentation), créant des clusters très spécifiques (ex : un cluster dédié uniquement aux extensions Chrome).

4 Optimisation du nombre de clusters (k)

Pour déterminer la valeur optimale de k , deux méthodes ont été implémentées :

4.1 Méthode du Coude (Elbow Method)

Cette méthode analyse l'évolution de l'**Inertie** (WCSS). Le point de rupture de la pente (le "coude") indique le meilleur compromis. Sur ce corpus, le coude est observé entre $k = 2$ et $k = 3$.

4.2 Coefficient de Silhouette

Le score de silhouette mesure la qualité de séparation entre les clusters. Le score maximal est obtenu pour $k = 2$ ($s \approx 0.15$), confirmant que la structure la plus stable divise le corpus en deux thématiques majeures.

5 Conclusion

L'algorithme K-means a permis de regrouper efficacement les documents similaires. L'analyse combinée du coude et de la silhouette démontre que la valeur optimale pour ce corpus est $k = 2$, reflétant les deux catégories dominantes (Chats et Google).