

Compte-rendu de TP : Clustering non supervisé

Analyse du dataset BBC News par K-Means

Malak — ENSAM Casablanca

17 mars 2026

1 Introduction

L'objectif de ce travail est d'appliquer l'algorithme de clustering K-Means sur un corpus de 2225 articles de presse (BBC News) répartis en 5 catégories. L'enjeu réside dans la capacité du modèle à reconstruire la structure thématique du dataset sans avoir accès aux étiquettes réelles durant la phase d'apprentissage.

2 Prétraitement et Réduction de Dimension

Les données textuelles ont été transformées en vecteurs numériques via une vectorisation **TF-IDF** (limitée aux 5000 termes les plus fréquents).

Compte tenu de la haute dimensionnalité et de la sparsité de la matrice obtenue, une **SVD tronquée** (Latent Semantic Analysis) a été appliquée pour réduire l'espace à 50 composantes. Cette étape est cruciale pour le K-Means, qui gère mal les distances Euclidiennes dans des espaces trop vastes (fléau de la dimensionnalité).

3 Détermination du nombre optimal de clusters (K)

Le choix de K a été validé par deux méthodes complémentaires :

- **Méthode du coude** : Observation de l'inertie intra-classe. Une cassure est visible aux alentours de $K = 5$.
- **Coefficient de Silhouette** : Un pic local de cohérence interne est observé à $K = 5$ ($s \approx 0.10$).

Une analyse exploratoire à $K = 6$ a révélé que l'algorithme tend à scinder la catégorie "Sport" en deux sous-groupes (sports de balle vs athlétisme), confirmant que $K = 5$ est le niveau de granularité le plus fidèle aux étiquettes d'origine.

4 Résultats et Évaluation

Pour comparer les résultats aux classes de départ, nous avons utilisé l'**algorithme hongrois** pour réaligner les indices de clusters avec les labels réels.

Métrique	Valeur
Adjusted Rand Index (ARI)	0.9077
Normalized Mutual Info (NMI)	0.8814
V-Mesure	0.8814
Précision (alignée)	96.13%

TABLE 1 – Performance du clustering K=5

4.1 Métriques de performance

4.2 Visualisation

La visualisation via **t-SNE** montre une séparation quasi-parfaite des clusters. Les rares chevauchements se situent entre "Politics" et "Business", ce qui est cohérent avec la proximité lexicale de ces domaines journalistiques.

5 Conclusion

L'algorithme K-Means, combiné à une réduction de dimension LSA, s'avère extrêmement performant pour ce dataset, atteignant plus de 96% de précision. L'utilisation de l'algorithme hongrois a permis de valider que la structure latente du texte correspond quasi-parfaitement aux catégories éditoriales de la BBC.