
Représentation du texte pour la classification de sentiments

Rapport de TP — Analyse comparative des méthodes de vectorisation

Étudiante Malak Mekyassi
Dataset IMDb Movie Reviews — 50 000 critiques
Tâche Classification binaire de sentiment (positif / négatif)
Classifieur Régression Logistique (protocole unifié)

Librairies utilisées : `scikit-learn`, `gensim`, `transformers`, `torch`, `datasets`, `matplotlib`

0. Contents

1	Cadre expérimental	3
1.1	Description du corpus	3
1.2	Variable cible	3
1.3	Sous-échantillonnage et découpage expérimental	3
1.4	Équilibre des classes	3
1.5	Classifieur de référence	3
2	Exploration du corpus	4
2.1	Longueur des textes	4
2.2	Vocabulaire caractéristique par classe	4
2.3	Niveau de bruit textuel	5
3	Prétraitement	5
3.1	Décisions de nettoyage	5
3.2	Justification des choix	5
4	Protocole de comparaison	6
5	Bag of Words	6
5.1	Principe	6
5.2	Réponses aux questions	6
5.3	Résultats	7
5.4	Analyse des coefficients	7
6	N-grams	7
6.1	Principe	7
6.2	Réponses aux questions	7
6.3	Résultats	8
7	TF-IDF	8
7.1	Principe	8
7.2	Réponses aux questions	8
7.3	Résultats	9
8	Comparaison des méthodes lexicales	9
8.1	Réponses aux questions de conclusion	9
9	Word Embeddings — Word2Vec	9
9.1	Principe	9
9.2	Réponses aux questions	10
9.3	Résultats	10
9.4	Interprétation guidée	10
10	FastText	10
10.1	Principe et apport des sous-mots	11
10.2	Réponses aux questions	11

10.3 Résultats et analyse	11
11 Embeddings contextuels — BERT (DistilBERT)	11
11.1 Principe	11
11.2 Réponses aux questions	12
11.3 Résultats et discussion	12
12 Évaluation commune et analyse des erreurs	12
12.1 Tableau comparatif final	13
12.2 Métriques et matrice de confusion	13
12.3 Analyse des erreurs	13
13 Questions de synthèse	13
14 Conclusion générale	14

1. Cadre expérimental

1.1 Description du corpus

Le dataset retenu pour ce travail pratique est le **IMDb Movie Reviews**, mis à disposition par Stanford NLP (Maas et al., 2011) et chargé via la bibliothèque HuggingFace **datasets**. Il s'agit d'un jeu de données de référence dans la communauté NLP pour la tâche d'analyse de sentiment.

Le corpus contient **50 000 critiques de films en anglais**, scindées en deux parties strictement symétriques :

Partition	Taille	Répartition
Entraînement	25 000 critiques	50 % positif / 50 % négatif
Test	25 000 critiques	50 % positif / 50 % négatif

1.2 Variable cible

La variable cible est binaire : une critique est étiquetée **positive (1)** si l'utilisateur a attribué une note élevée au film, et **négative (0)** dans le cas contraire. Il n'y a pas de valeur intermédiaire dans cette partition, ce qui simplifie la formulation du problème tout en le rendant représentatif d'une grande variété de cas réels.

1.3 Sous-échantillonnage et découpage expérimental

Pour des raisons de coût de calcul, notamment lors des phases impliquant Word2Vec, FastText et BERT, les expériences ont été conduites sur un sous-ensemble raisonnable. **Le découpage train/test est fixé une fois pour toutes** (80 %/20 %, graine aléatoire 42, stratification) et conservé identique pour l'ensemble des méthodes testées. Cela garantit que tout écart de performance observé entre deux représentations est attribuable à la représentation elle-même, et non à un biais introduit par un tirage différent.

1.4 Équilibre des classes

Les classes sont parfaitement équilibrées dans ce corpus, ce qui présente un avantage majeur : les métriques classiques (accuracy, F1 macro) sont directement comparables entre les méthodes sans nécessiter de correction pour le déséquilibre. C'est l'une des raisons pour lesquelles IMDb est devenu un benchmark incontournable en NLP.

1.5 Classifieur de référence

Pour isoler la contribution de chaque méthode de représentation, un unique classifieur est utilisé dans toutes les expériences : la **Régression Logistique** (`max_iter=1000`). Ce choix s'inscrit dans une logique de contrôle expérimental : on ne cherche pas à optimiser le classifieur, mais bien à mesurer la qualité informationnelle de la représentation.

2. Exploration du corpus

2.1 Longueur des textes

Une première analyse exploratoire a été conduite sur la longueur des avis (en nombre de mots). Les statistiques descriptives obtenues sur le jeu d'entraînement sont les suivantes :

Statistique	Classe négative (0)	Classe positive (1)
Moyenne	230,9 mots	236,7 mots
Médiane	174 mots	174 mots
Écart-type	166,7	180,5
Minimum	10 mots	12 mots
Maximum	1 522 mots	2 470 mots

Ces chiffres révèlent plusieurs éléments importants. D'abord, la longueur médiane est identique pour les deux classes (174 mots), ce qui signifie que le signal de sentiment ne vient pas d'une différence de verbosité. En revanche, l'écart-type élevé et l'étendue importante (10 à plus de 2000 mots) indiquent une **forte hétérogénéité** dans les textes. Certains avis sont des paragraphes très brefs, d'autres de véritables essais critiques.

Cette hétérogénéité a une implication directe sur les méthodes de représentation : des approches comme la moyenne de vecteurs Word2Vec ou la troncature à 256 tokens de BERT peuvent perdre une fraction non négligeable de l'information pour les textes les plus longs.

2.2 Vocabulaire caractéristique par classe

L'application d'un TF-IDF sur chacune des classes séparément, en ne conservant que les 20 termes les plus caractéristiques, permet d'observer les mots à faible IDF (donc très présents dans la classe) :

- **Classe négative** : movie, br, film, like, just, good, bad, time, really, don, make, story, acting, people, plot
- **Classe positive** : br, film, movie, like, good, just, time, great, story, really, best, way, people, love, life

Ce qui frappe immédiatement, c'est le fort recouvrement entre les deux listes. Des termes comme **film**, **movie**, **story** ou **just** sont omniprésents dans les deux classes, ce qui confirme qu'ils n'apportent quasiment aucun signal discriminant. Les quelques différences notables — **bad** côté négatif, **great**, **best**, **love** côté positif — laissent entrevoir que le vocabulaire du sentiment est réel mais dilué dans une masse de termes génériques.

La présence de **br** dans les deux listes s'explique par du bruit HTML (`<br/>`), non éliminé à ce stade de l'analyse.

2.3 Niveau de bruit textuel

Un test de présence de balises HTML (`<br/>` notamment) révèle que **14 667 critiques sur 25 000** en contiennent, soit plus de la moitié du corpus d'entraînement. Ce bruit est systématique et doit impérativement être traité avant toute vectorisation, sans quoi les tokens correspondants viendront polluer l'espace vectoriel sans apporter aucune information sémantique.

3. Prétraitement

3.1 Décisions de nettoyage

La fonction de nettoyage appliquée au corpus effectue quatre opérations successives :

1. mise en minuscules (`lower()`) ;
2. suppression des balises HTML de type `<br/>` (remplacées par un espace) ;
3. suppression de tous les caractères non alphabétiques, à l'exception de l'apostrophe ;
4. normalisation des espaces multiples.

3.2 Justification des choix

Suppression des balises HTML. C'est un choix évident ici : `<br/>` n'est pas un marqueur de sentiment, et sa présence dans plus de 58 % des textes en ferait un terme d'apparence très fréquent et trompeur.

Conservation de l'apostrophe. En anglais, les contractions (`don't`, `won't`, `it's`) portent souvent une information contextuelle importante pour le sentiment. Supprimer l'apostrophe transformerait `don't` en `dont`, un token non standard que les modèles auront du mal à associer à sa négation.

Faut-il supprimer les stopwords ? Cette question mérite réflexion. Dans une tâche de classification de sentiment, les mots de négation comme `not`, `no`, `never` jouent un rôle crucial : ils inversent le sens d'une phrase. Supprimer automatiquement tous les stopwords — comme le font beaucoup de pipelines génériques — reviendrait à transformer *not good* en *good*, ce qui est sémantiquement catastrophique. Dans ce TP, les stopwords ont donc été conservés.

Normalisation en minuscules. La casse ne transporte généralement pas d'information de sentiment dans ce type de corpus. La normalisation réduit la dimensionnalité du vocabulaire sans perte significative.

4. Protocole de comparaison

La rigueur expérimentale impose de figer plusieurs paramètres avant toute comparaison :

- **Découpage train/test identique** pour toutes les méthodes (80 %/20 %, stratifié, graine 42) ;
- **Classifieur unique** : Régression Logistique avec `max_iter=1000` ;
- **Métriques identiques** : accuracy et F1 macro ;
- **Prétraitement identique** : texte nettoyé (`text_clean`) pour les méthodes lexicales.

Ce protocole garantit que les différences de performance observées sont imputables à la *représentation* et non à des choix de modélisation ou de données.

5. Bag of Words

5.1 Principe

Le Bag of Words (**BoW**) est la représentation textuelle la plus simple qui soit. Chaque document est transformé en un vecteur de dimension égale à la taille du vocabulaire, où chaque composante correspond au nombre d'occurrences d'un terme dans le document. L'ordre des mots est totalement ignoré.

5.2 Réponses aux questions

Ce que conserve cette représentation. BoW retient l'ensemble des termes présents dans un document et leur fréquence d'apparition. Pour une tâche de sentiment, cela suffit souvent à capturer les mots affectivement chargés — *excellent*, *horrible*, *boring* — qui sont de bons prédicteurs de polarité.

Ce qu'elle perd. L'information d'ordre est entièrement perdue. La phrase *not bad* et la phrase *bad, not really* auront des représentations très similaires, voire identiques si on ne considère que les fréquences individuelles. La syntaxe, la négation, l'ironie — autant de phénomènes discursifs importants en analyse de sentiment — sont complètement absents de cette représentation.

Pourquoi reste-t-elle performante sur IMDb ? Le corpus IMDb est relativement direct dans son langage : les critiques utilisent des qualificatifs explicites (*brilliant*, *awful*, *masterpiece*, *waste*) qui sont de forts indicateurs de sentiment même pris isolément. Dans ce contexte, une représentation par sac de mots suffit à capturer l'essentiel du signal.

Types d'erreurs produits. Les erreurs les plus attendues concernent les phrases à polarité inversée par la négation (*not good* interprété comme *good*), les formulations ironiques (*what a masterpiece of boredom*) et les textes neutres à vocabulaire ambigu.

5.3 Résultats

Méthode	Accuracy	F1 macro
Bag of Words (BoW)	0.875	0.8750

5.4 Analyse des coefficients

L'inspection des coefficients de la régression logistique donne les résultats suivants :

- **Mots positivement associés à la classe positive** : excellent, perfect, wonderfully, refreshing, funniest, flawless, appreciated, cerebral
- **Mots positivement associés à la classe négative** : worst, waste, awful, horrible, laughable, fails, lacks, poorly

Le modèle a effectivement appris à s'appuyer sur des marqueurs sentimentaux explicites et directement interprétables. Il est sensible aux mots porteurs de sens émotionnel fort, mais pas à leur contexte d'apparition. Une phrase comme *this is not the worst film I've seen* serait probablement mal classifiée, car le mot *worst* tire le score vers la classe négative indépendamment de la négation qui le précède.

6. N-grams

6.1 Principe

Les n-grams étendent BoW en construisant des séquences de n mots consécutifs. Un bigramme comme *not good* devient un token à part entière, distinct de *not* et de *good* pris séparément. Dans ce TP, une plage de n-grams (1,2) a été utilisée, c'est-à-dire unigrammes et bigrammes simultanément.

6.2 Réponses aux questions

Ce qu'apportent les bigrammes. Les bigrammes capturent des expressions locales à deux mots qui ont souvent une valeur sémantique propre : *not good*, *waste of* (précédant souvent *time* ou *money*), *highly recommend*, *very boring*. Ces associations sont précisément celles que BoW ne peut pas distinguer de leurs composants isolés.

Pourquoi les trigrammes sont-ils plus rares ? La probabilité d'observer une séquence de trois mots identiques dans deux documents distincts diminue rapidement avec n . Les trigrammes souffrent donc d'une très forte dispersion : la majorité des trigrammes possibles n'apparaissent que dans un ou deux documents, ce qui rend leurs représentations peu fiables statistiquement. La dimensionnalité explose sans réel gain de couverture.

Compromis. Pour ce corpus, les bigrammes offrent un gain mesurable sans faire exploser la complexité. L'usage de `max_features=15 000` permet de retenir les n-grams les plus fréquents et informatifs.

6.3 Résultats

Méthode	Accuracy	F1 macro
N-grams (1,2)	0.8886	0.8886

Le gain par rapport à BoW pur (+1,4 points d'accuracy) confirme que la prise en compte des associations locales apporte bien une information complémentaire, en particulier pour les expressions de négation et les locutions figées courantes dans les critiques de films.

7. TF-IDF

7.1 Principe

TF-IDF (*Term Frequency – Inverse Document Frequency*) corrige la fréquence brute d'un terme par son ubiquité dans le corpus. Un mot présent dans tous les documents reçoit un poids IDF faible, même s'il apparaît souvent dans un document donné. À l'inverse, un terme rare mais concentré dans certains documents reçoit un poids élevé.

7.2 Réponses aux questions

Quels mots sont naturellement pénalisés ? Les mots très fréquents et peu discriminants — *the, is, film, movie* — voient leur poids réduit par l'IDF. Ce sont précisément les mots qui apparaissaient en tête des listes de BoW et qui n'apportent aucun signal de sentiment.

Pourquoi TF-IDF est-il souvent supérieur à BoW ? BoW donne trop de poids aux mots fréquents qui sont également les moins informatifs. TF-IDF rééquilibre automatiquement cette pondération : un terme rare mais diagnostique (comme *pretentious* ou *mesmerizing*) contribuera davantage à la représentation TF-IDF qu'à un BoW brut.

Dans quels cas la différence reste-t-elle faible ? Si le vocabulaire du corpus est suffisamment spécialisé et que la plupart des mots informatifs n'apparaissent que dans une sous-population de documents, BoW et TF-IDF convergent. Sur un corpus court ou très homogène, les deux méthodes peuvent produire des performances similaires.

TF-IDF "comprend"-il mieux le texte ? Non, pas au sens où l'on entendrait une compréhension sémantique. TF-IDF est toujours une représentation locale, sans notion d'ordre ou de contexte. Sa supériorité sur BoW est purement mécanique : il réduit le bruit statistique dû aux mots trop fréquents. C'est un filtre sur la qualité du signal lexical, pas une avancée conceptuelle sur la représentation du sens.

7.3 Résultats

Méthode	Accuracy	F1 macro
TF-IDF + bigrammes	0.8944	0.8944

TF-IDF avec bigrammes obtient la meilleure performance parmi toutes les méthodes testées dans ce TP, dépassant légèrement les N-grams et de façon plus notable le BoW pur.

8. Comparaison des méthodes lexicales

Méthode	Accuracy	F1 macro	Temps	Interprétabilité
TF-IDF (1,2)	0.8944	0.8944	Très rapide	Haute
N-grams (1,2)	0.8886	0.8886	Rapide	Haute
BoW	0.8750	0.8750	Très rapide	Haute

8.1 Réponses aux questions de conclusion

Quelle méthode offre le meilleur compromis ? TF-IDF avec bigrammes offre la meilleure performance (0.8944 en accuracy) avec un coût de calcul encore très faible et une excellente interprétabilité des poids. C'est la méthode lexicale à privilégier.

La meilleure performance est-elle la plus interprétable ? Ici, oui — et c'est une propriété précieuse. TF-IDF est à la fois le plus performant parmi les méthodes lexicales et l'un des plus faciles à inspecter : il est possible d'identifier exactement quels mots influencent chaque prédiction, ce qui facilite le débogage et l'explication des décisions.

Quelle méthode en déploiement rapide ? TF-IDF reste la recommandation naturelle dans un contexte de déploiement rapide où les ressources de calcul sont limitées. Il est simple à entraîner, à sérialiser, et ses prédictions sont explicables — une exigence de plus en plus fréquente dans les applications industrielles.

9. Word Embeddings — Word2Vec

9.1 Principe

Word2Vec entraîne des représentations vectorielles denses dans un espace continu de faible dimension (ici 100 dimensions). Contrairement à BoW/TF-IDF, deux mots sémantiquement proches se retrouvent proches dans cet espace. Le mode Skip-Gram utilisé ici cherche à prédire le contexte d'un mot à partir du mot lui-même.

Pour obtenir une représentation de document, chaque texte est résumé par la **moyenne** des vecteurs de ses mots.

9.2 Réponses aux questions

Que signifie une proximité dans l'espace vectoriel ? Deux mots proches au sens cosinus partagent des contextes d'apparition similaires dans le corpus. Cette proximité est sémantique, mais aussi distributionnelle : des synonymes, des hyperonymes, ou des mots appartenant au même champ lexical se retrouvent proches, indépendamment de leur forme.

Pourquoi un embedding peut-il capturer de la similarité sémantique ?

Parce qu'il est entraîné sur la co-occurrence : si *excellent* et *brilliant* apparaissent dans des contextes similaires (avec les mêmes voisins dans le corpus), leurs vecteurs seront projetés dans des régions proches de l'espace. Cette propriété permet au modèle de généraliser au-delà des formes de surface.

Ce que l'on perd avec la moyenne. La moyenne des vecteurs efface l'ordre des mots et mélange des informations potentiellement contradictoires. Une critique comme *starts brilliantly but ends in disaster* produira un vecteur moyen qui se situera quelque part entre les deux polarités, rendant la classification difficile. L'information de structure séquentielle est totalement perdue.

9.3 Résultats

Méthode	Accuracy	F1 macro
Word2Vec (moyenne)	0.8362	0.8362

9.4 Interprétation guidée

Le résultat est contre-intuitif : Word2Vec, techniquement plus sophistiqué que TF-IDF, obtient une accuracy **inférieure de 5,8 points**. Plusieurs raisons l'expliquent.

D'abord, le corpus d'entraînement de Word2Vec ici est le corpus IMDb lui-même (25 000 critiques), ce qui est relativement modeste pour apprendre des embeddings robustes. Les représentations pré-entraînées sur des corpus massifs (Wikipedia, Common Crawl) sont généralement bien supérieures à des embeddings entraînés *from scratch* sur des données limitées.

Ensuite, l'opération de moyenne est destructive. Elle gomme non seulement l'ordre des mots, mais aussi les nuances de polarité : deux mots de sentiment opposé (par exemple dans une critique mitigée) se neutralisent mutuellement. TF-IDF, en conservant l'ensemble des dimensions lexicales, permettait au classifieur d'exploiter directement les mots les plus discriminants.

Enfin, les mots rares ou spécifiques au domaine (noms d'acteurs, titres de films) peuvent ne pas avoir de vecteurs bien appris avec `min_count=2`, introduisant du bruit dans la représentation finale.

10. FastText

10.1 Principe et apport des sous-mots

FastText étend Word2Vec en décomposant chaque mot en **n-grammes de caractères**. Le vecteur d'un mot est la somme de ses sous-mots. Cette architecture apporte deux avantages majeurs.

10.2 Réponses aux questions

En quoi cela aide-t-il pour les mots rares ? Un mot jamais vu en entraînement (*out-of-vocabulary*) peut quand même être représenté, car il partage des sous-mots avec des mots connus. Par exemple, *superbe* et *superbement* partagent le préfixe *superb-*, ce qui permet une certaine généralisation morphologique.

Robustesse aux fautes d'orthographe. Une faute de frappe comme *brillant* au lieu de *brilliant* partage une majorité de trigrammes de caractères avec le mot correct. FastText produit alors un vecteur proche de celui du mot correctement orthographié, là où Word2Vec serait totalement perdu. Cette propriété est précieuse pour des corpus issus du web, où les fautes sont fréquentes.

Dans quelles langues est-ce particulièrement utile ? FastText est particulièrement adapté aux langues à morphologie riche : l'arabe, le finnois, le turc, l'allemand, ou encore le français, où les variations de genre, nombre et conjugaison créent de nombreuses formes à partir d'une même racine. En anglais, la morphologie est plus pauvre, ce qui explique en partie que le gain de FastText soit plus modeste sur IMDb.

10.3 Résultats et analyse

Méthode	Accuracy	F1 macro
FastText (moyenne)	0.8196	—

FastText est ici légèrement inférieur à Word2Vec. La raison tient moins à une faiblesse intrinsèque de FastText qu'à la nature du corpus : IMDb est en anglais, une langue à morphologie simple, et les textes sont relativement propres après nettoyage. L'avantage principal de FastText — la gestion des formes inconnues via les sous-mots — est donc peu sollicité ici. Dans une tâche sur du contenu très bruité (réseaux sociaux, SMS), l'avantage de FastText serait beaucoup plus visible.

Il est important de noter que FastText comprend *mieux les formes morphologiques*, pas nécessairement *mieux les émotions*. Sa supériorité potentielle vient d'une meilleure couverture du vocabulaire, pas d'une représentation plus riche du sens.

11. Embeddings contextuels — BERT (DistilBERT)

11.1 Principe

BERT (*Bidirectional Encoder Representations from Transformers*) rompt avec toutes les approches précédentes : le vecteur d'un mot n'est plus fixe, il **dépend du contexte complet dans lequel le mot apparaît**. Dans la phrase *the bank of the river*, le mot

bank aura un vecteur différent que dans *I went to the bank*. Pour ce TP, la variante **DistilBERT** (une version distillée, 40 % plus légère) a été utilisée, et les textes ont été représentés par l’embedding du token [CLS].

11.2 Réponses aux questions

Pourquoi la négation est-elle mieux traitée ? Dans un modèle de type Transformer, chaque token *assiste* à tous les autres tokens via le mécanisme d’attention. Le token *good* dans *not good* assiste au token *not* : son vecteur contextuel intègre donc la présence de la négation. C’est structurellement impossible pour BoW ou TF-IDF, où *not* et *good* sont des dimensions indépendantes.

Pourquoi BERT distingue-t-il mieux les contextes ? L’attention multi-têtes lui permet de pondérer dynamiquement les relations entre tokens, quelle que soit leur distance dans la phrase. Un qualificatif situé en fin de phrase peut influencer le vecteur d’un sujet situé en début de phrase, ce qu’aucune représentation locale ne peut capturer.

L’apport du contexte bidirectionnel. Contrairement à un modèle de langue unidirectionnel (GPT), BERT lit la phrase dans les deux sens simultanément. Pour le sentiment, cela signifie qu’un mot est toujours représenté en tenant compte de ce qui le précède ET de ce qui le suit.

11.3 Résultats et discussion

Méthode	Accuracy	F1 macro
DistilBERT + Logistic Regression	0.8375	0.8367

Ces résultats, contre-intuitifs au premier abord, s’expliquent par le protocole utilisé : BERT a été appliqué ici comme un **extracteur de features figé**, sans fine-tuning sur la tâche cible. On extrait simplement l’embedding [CLS] et on entraîne une régression logistique par-dessus. Or, BERT pré-entraîné produit des représentations optimisées pour les tâches de pré-entraînement (masked language modeling), pas directement pour la classification de sentiment. Le fine-tuning — c’est-à-dire l’adaptation de l’ensemble des paramètres de BERT sur les données IMDb — atteint typiquement 93-95 % d’accuracy sur ce benchmark.

Par ailleurs, la troncature à 256 tokens implique une perte d’information pour les textes longs, et l’application sur un sous-échantillon réduit la représentativité des embeddings calculés.

12. Évaluation commune et analyse des erreurs

12.1 Tableau comparatif final

Méthode	Type	Accuracy	F1 macro	Temps
TF-IDF (1,2)	Lexicale pondérée	0.8944	0.8944	Très rapide
N-grams (1,2)	Séquentielle locale	0.8886	0.8886	Rapide
BoW	Lexicale	0.8750	0.8750	Très rapide
DistilBERT	Contextuel	0.8375	0.8367	Lent
Word2Vec	Embedding statique	0.8362	0.8362	Moyen
FastText	Embedding sous-mots	0.8196	—	Moyen

12.2 Métriques et matrice de confusion

Quelle métrique en cas de déséquilibre ? Le F1 macro reste la métrique la plus informative lorsque les classes sont déséquilibrées, car il calcule la moyenne non pondérée du F1 par classe, évitant ainsi qu’une classe majoritaire ne masque les performances sur la classe minoritaire. Sur IMDB les classes sont équilibrées, donc accuracy et F1 macro convergent — mais dans un contexte réel, le F1 macro est à privilégier.

Ce que révèle la matrice de confusion. La matrice de confusion de TF-IDF montre que les erreurs sont réparties de manière assez symétrique entre faux positifs et faux négatifs. Cela confirme la difficulté intrinsèque de certains exemples (négation, ironie) plutôt qu’un biais systématique du modèle.

12.3 Analyse des erreurs

Les erreurs sont-elles aléatoires ? Non. Une inspection qualitative révèle des patterns récurrents :

- les textes contenant de la **négation** (*not bad, never disappoints, couldn't be better*) sont particulièrement problématiques pour les méthodes lexicales ;
- les **textes très courts** manquent de contexte suffisant pour une classification fiable, quelle que soit la méthode ;
- les **critiques mitigées** (positives dans l’ensemble mais avec des réserves, ou négatives avec des points positifs) sont difficiles pour toutes les méthodes.

Les méthodes lexicales et les embeddings échouent-elles sur les mêmes cas ? En grande partie oui, du moins pour les méthodes testées ici sans fine-tuning. BERT en mode extracteur de features n’apporte pas de gain systématique sur les cas difficiles, car ses représentations ne sont pas adaptées à cette tâche sans ajustement.

13. Questions de synthèse

Quelle méthode est la plus adaptée à ce corpus ? Sur ce corpus et dans ce protocole, **TF-IDF avec bigrammes** s’avère la méthode la plus performante. C’est un résultat qui illustre une réalité souvent sous-estimée en NLP : la sophistication d’un modèle n’est pas une garantie de supériorité. IMDB est un corpus dans lequel le

signal de sentiment est porté en grande partie par des marqueurs lexicaux explicites et récurrents — exactement ce que TF-IDF capture très bien. Les embeddings, entraînés sur ce seul corpus et utilisés sans fine-tuning, ne parviennent pas à exploiter leur capacité de généralisation sémantique de manière efficace.

La meilleure méthode est-elle la plus interprétable ? Dans ce cas précis, oui. TF-IDF produit des vecteurs de grande dimension mais parfaitement lisibles : on peut inspecter les poids du classifieur pour identifier exactement quels termes influencent la décision. Ce n'est pas toujours le cas : dans de nombreux autres contextes, les méthodes les plus performantes (BERT fine-tuné, modèles de grande taille) sont aussi les moins transparentes. La co-incidence ici entre performance et interprétabilité est une propriété heureuse du corpus et de la tâche, pas une règle générale.

Quel compromis entre précision, coût et explicabilité ? Pour un déploiement en production rapide, TF-IDF est le choix naturel. Pour une application nécessitant une compréhension sémantique fine — traitement de textes ambigus, multilingues, ou très bruités — un BERT fine-tuné serait à privilégier, au prix d'un coût de calcul et d'une complexité de déploiement bien supérieurs. FastText représente un compromis intéressant dans les langues à morphologie riche ou sur des corpus fortement bruités.

Si l'on disposait de plus de données, le classement changerait-il ? Probablement oui. Les méthodes basées sur les embeddings (Word2Vec, FastText) souffrent en priorité d'un manque de données d'entraînement pour leurs représentations vectorielles. Sur un corpus dix fois plus grand, les embeddings appris *from scratch* seraient plus robustes. BERT fine-tuné bénéficierait également de données supplémentaires pour adapter ses paramètres. Les méthodes lexicales, en revanche, ont tendance à plafonner plus vite : au-delà d'une certaine taille de vocabulaire, TF-IDF n'apprend plus grand chose de nouveau. On peut donc anticiper que sur des corpus massifs, les embeddings et surtout les Transformers fine-tunés prendraient l'avantage.

14. Conclusion générale

Ce travail pratique a permis de parcourir de manière progressive et structurée le spectre des représentations textuelles disponibles pour une tâche de classification de sentiment. Partant des approches les plus simples — Bag of Words et TF-IDF — jusqu'aux embeddings denses et aux Transformers, l'expérimentation conduite sur le corpus IMDb a mis en lumière plusieurs enseignements.

Le premier est d'ordre méthodologique : **la qualité d'une représentation ne s'évalue qu'en contexte**. Une représentation sophistiquée peut être moins performante qu'une approche simple si les hypothèses implicites du modèle ne correspondent pas à la nature des données. Ici, le vocabulaire explicitement sentimental d'IMDb favorise les approches lexicales, qui capturent précisément ce type de signal.

Le second concerne le **protocole de comparaison**. Figer le découpage des données, le classifieur et les métriques a été essentiel pour attribuer correctement les différences

de performance aux représentations plutôt qu'à d'autres facteurs. Ce principe de contrôle expérimental est une bonne pratique fondamentale en machine learning, souvent négligée dans la précipitation.

Le troisième porte sur les **compromis en pratique**. TF-IDF est rapide, interprétable et compétitif — des qualités rares qui en font un choix par défaut solide. Les embeddings contextuels (BERT) sont plus puissants en théorie, mais nécessitent un fine-tuning pour révéler leur plein potentiel. Utilisés comme simples extracteurs de features, ils ne surpassent pas les méthodes lexicales classiques sur ce type de benchmark.

Enfin, l'analyse des erreurs a rappelé que les cas difficiles — négation, ironie, critiques mitigées — restent un défi pour toutes les méthodes. C'est précisément là que la direction vers les modèles contextuels, correctement fine-tunés, semble la plus prometteuse pour de futures expérimentations.